



SISTEMA INTELIGENTE PARA DESCOBERTA EM ASTRONOMIA

Especificação Detalhada

PCS3550 – Projeto de Formatura I

Natanael Magalhães Cardoso

ORIENTADOR: Prof. Dr. Antonio Mauro Saraiva



**Universidade de São
Paulo**

Escola Politécnica

Departamento de Eng. da
Computação e Sist. Digitais



UNIVERSIDADE DE SÃO PAULO
ESCOLA POLITÉCNICA

Departamento de Eng. da Computação e Sist. Digitais



Sistema Inteligente para Descoberta em Astro- nomia

Natanael Magalhães Cardoso^{★,✉}, Prof. Dr. Antonio Mauro Saraiva^{★,†}

I N F O

★ Departamento de Engenharia de Computação e Sistemas Digitais, Escola Politécnica, Universidade de São Paulo.

† Orientador

✉ contato@natanael.net

Palavras-chave: base de conhecimento, visão computacional, vision transformers, aprendizagem profunda, busca por similaridade, astronomia extra-galática, classificação morfológica.

R E S U M O

A astronomia produz um volume imenso de dados, principalmente na forma de imagens capturadas por telescópios e outros instrumentos. A análise dessas imagens é vital para entender o universo, descobrir novos objetos celestes e fenômenos astronômicos. Nesse sentido, este projeto aborda a aplicação de métodos de aprendizagem profunda e visão computacional na astronomia, com ênfase na análise de imagens astronômicas. O objetivo é criar um sistema inteligente que facilite descobertas astronômicas composto por um modelo de aprendizagem profunda capaz de extrair representações visuais de alta qualidade, uma base de dados para armazenar as representações obtidas e uma aplicação web para possibilitar uma exploração intuitiva de uma base dados astronômica.


SUMÁRIO

1	Introdução	5
2	Metodologia	7
2.1	Revisão Bibliográfica	8
2.1.1	Definição dos Objetivos e das Fontes de Informação	8
2.1.2	Seleção e Análise dos Estudos	9
2.1.3	Síntese e Documentação dos Estudos	9
2.2	Conjunto de Dados	10
2.2.1	Requisitos Funcionais e Não Funcionais	10
2.2.2	Protocolos e Padrões de Dados em Astronomia	10
2.2.3	Aquisição de Dados de Levantamentos Astronômicos	11
2.2.4	Sistema de Coordenas Celeste	11
2.2.5	Análise dos Dados	13
2.3	Modelo de Aprendizagem Profunda	13
2.3.1	Seleção da Arquitetura	13
2.3.2	Pré-processamento dos Dados	13
2.3.3	Treinamento	13
2.3.4	Avaliação e Melhoria	14
2.3.5	Inferência	14
2.4	Banco de Dados e Algoritmos de Busca	14
2.4.1	Design do Banco de Dados	14
2.4.2	Indexação e Recuperação	14
2.4.3	Testes de Desempenho	15

2.5	Aplicação Web	15
2.5.1	Design de Interface do Usuário	15
2.5.2	Implementação Front-end e Back-end	15
2.5.3	Testes de Usabilidade	15
2.6	Sistema Inteligente para Descobertas em Astronomia	15
2.6.1	Integração dos Módulos	15
2.6.2	Testes do Sistema	16
2.7	Comparação dos resultados	16
2.7.1	Identificação dos Critérios de Comparação	16
2.7.2	Coleta de Dados Comparativos	16
2.7.3	Análise e Discussão	16
3	Resultados Esperados	17
4	Conclusão	17
5	Cronograma	19

1. INTRODUÇÃO

A astronomia é uma das ciências que mais gera dados, especialmente na forma de imagens obtidas através de telescópios terrestres e espaciais e instrumentos acoplados a estes (KREMER et al., 2017). A análise dessas imagens é crucial para a compreensão de como funciona o universo e responder perguntas tão fundamentais quanto de onde viemos e para onde vamos. A análise de imagens astronômicas também é importante para a descoberta de novos objetos celestes de tipos já conhecidos e até mesmo de novos fenômenos astronômicos, nunca antes vistos, trazendo novos desafios e novas perguntas a serem respondidas. Em 10 de abril de 2019, por exemplo, foi publicado o primeiro imageamento de um buraco negro, no centro da galáxia de M87, com imagens maravilhosas, como da Fig. 1, que correram os jornais do mundo inteiro (THE EVENT HORIZON TELESCOPE COLLABORATION et al., 2019).



■ **Figura 1:** Primeiro imageamento de um buraco negro. Fonte: *The Event Horizon Telescope Collaboration et al., 2019*.

Outro bom exemplo foi o que aconteceu em agosto de 2017, quando houve a primeira detecção em imagem óptica de uma onda gravitacional vinda da fusão de duas estrelas de nêutrons. Essas são estrelas muito densas, já colapsadas, em um sistema binário, que quando se fundem provocam uma explosão parecida mas menos intensa que de uma supernova, formando o que é chamado de uma kilonova. O mundo inteiro se empolgou com tal fenômeno, pois se sabia que o ocorrido seria visto em alguma imagem do céu naquela noite, mas não se sabia exatamente onde (a área de procura no céu onde poderia acontecer era enorme). Finalmente a contrapartida óptica da onda gravitacional foi encontrada, também por brasileiros (DÍAZ et al., 2017), e foi seguida por quase uma centena de telescópios no mundo inteiro por várias noites e desde então a comunidade astronômica procura por outros eventos do mesmo tipo, vasculhando imagens obtidas todas as noites¹.

O volume crescente de dados astronômicos, à medida que as pesquisas continuam, torna a tarefa de localizar e analisar imagens específicas extremamente desafiadora para os astrônomos (MARQUEZ e NORD, 2019). Tradicionalmente, a busca por imagens astronômicas é realizada através de metadados previamente extraídos de imagens processadas, como a localização no céu (latitude e longitude), propriedades físicas (como o brilho e o diâmetro) e, até mesmo, anotações manuais. Todavia, esse método é limitado e não explora plenamente a riqueza visual contida nas imagens, além de não escalar bem com a quantidade massiva de dados gerada na era dos grandes levantamentos astronômicos, que são telescópios destinados à observação contínua e geração de dados em larga escala.

A cada década se constroem telescópios cada vez maiores, como por exemplo o *Giant Magellan Telescope* (GMT, FANSON et al., 2022) e o *Extremely Large Telescope* (ELT, PADOVANI e CIRASUOLO, 2023) ou se constroem telescópios com cada vez mais capacidade de se obter dados, como o *Large Synoptic Survey Telescope* (LSST) ou *Vera Rubin Observatory* (IVEZIĆ et al., 2019). Esse último, o *LSST/Vera Rubin* é uma das motivações deste projeto. Trata-se de um projeto que irá começar a tomar dados no próximo ano e haverá um volume de petabytes de dados a cada ano provenientes deste telescópio, imagens que têm que ser exploradas de forma eficiente. Este trabalho é um esforço de fazer ferramentas para explorar tais dados no

¹<https://www.gov.br/observatorio/pt-br/assuntos/noticias/imagens-fusao-estrelas-neutrons>

futuro. Neste trabalho, serão usadas as imagens do levantamento *Legacy Survey* (DEY et al., 2019) obtidas pelo instrumento *Dark Energy Camera*, que têm uma estrutura muito parecida com as imagens que serão obtidas pelo projeto futuro *LSST/Vera Rubin*.

Através de discussões com astrônomos profissionais e professores do IAG que estão acostumados a lidar com imagens astronômicas e estão preocupados com a enorme quantidade de dados que o LSST trará, quando começar a funcionar, definimos a direção deste trabalho para que seja útil também para a comunidade astronômica. Nós identificamos que o importante no momento para a exploração das imagens em grandes levantamentos como os do *Dark Energy Survey* ou LSST, é desenvolver uma forma automática de realizar buscas por similaridade visual em grandes conjuntos de dados astronômicos. Isso é possível devido à capacidade de extração de representações visuais pelos modelos atuais de visão computacional (TULI et al., 2021).

Nas últimas décadas, muitas das classificações de galáxias e objetos raros em imagens foram feitas por inspeção do olho humano através do *Galaxy Zoo* (LINTOTT et al., 2008), um projeto de ciência cidadã (BONNEY et al., 2016; FRIGERIO et al., 2021) que inseriu pela primeira vez na área a colaboração voluntária de membros da sociedade no processo de construção do conhecimento científico em astronomia. Ao decorrer de várias campanhas, o *Galaxy Zoo* coletou milhões de classificações visuais humanas provenientes dos voluntários e que estão disponíveis para uso na ciência.

2. METODOLOGIA

O desenvolvimento do sistema inteligente para buscas em astronomia conta com apoio da Profa. Dra. Cláudia Mendes de Oliveira do Grupo de Astronomia Extragalática do Departamento de Astronomia do Instituto de Astronomia, Geofísica e Ciências Atmosféricas (IAG) da Universidade de São Paulo (USP) e será realizado em etapas estruturadas e modulares.

As subseções a seguir, que detalham a metodologia proposta para o desenvolvimento deste trabalho, englobam desde a revisão literária (Seção 2.1), passando por

todas etapas técnicas de implementação (Seções 2.2, 2.3, 2.4, 2.5), até a comparação dos resultados obtidos com outros trabalhos na literatura (Seção 2.7).

2.1. REVISÃO BIBLIOGRÁFICA

A revisão bibliográfica para este projeto multidisciplinar será realizada de maneira abrangente e sistemática, envolvendo as áreas de aprendizagem profunda, visão computacional e astronomia, como descrito nas subseções a seguir.

2.1.1 Definição dos Objetivos e das Fontes de Informação

É necessário estabelecer os objetivos específicos da revisão, identificando as principais áreas de estudo a serem abordadas, incluindo métodos de aprendizado profundo, técnicas de visão computacional aplicadas à análise de imagens astronômicas e sistemas de busca por similaridade visual.

Para tanto, é importante utilizar diversas bases de dados acadêmicas relevantes para as áreas de computação e astronomia, como o Portal Periódicos (www.periodicos.capes.gov.br), o Google Scholar (<https://scholar.google.com>) e o *Astrophysics Data System* (ADS) (www.adsabs.harvard.edu), além de conferências relevantes nas áreas de inteligência artificial, processamento de imagens e astronomia, como a *International Conference on Machine Learning* (ICML), a *International Conference on Computer Vision* (ICCV) e a *Astronomical Data Analysis Software and Systems Conference* (ADASS).

Além disso, repositórios de *pré-prints*, como o arXiv (www.arxiv.org), mantido pela *Cornell University*, ou o TechRxiv (www.techrxiv.org), mantido pelo *Institute of Electrical and Electronics Engineers* (IEEE), são especialmente úteis por ser um repositório de artigos ainda publicados, sendo úteis para manter a atualização dos estudos emergentes.

A pesquisa em repositórios de produção científica das diferentes áreas – astronomia, visão computacional e aprendizagem profunda – abrirá novos horizontes de conhecimento, pois a integração de conhecimentos multidisciplinares promoverá avanços significativos, não apenas no contexto do projeto, mas também contribuindo para o progresso das áreas de estudo envolvidas.

2.1.2 Seleção e Análise dos Estudos

Para selecionar estudos relevantes para este trabalho dentre o vasto repertório científico disponível, é importante aplicar critérios de inclusão e exclusão para selecionar artigos, livros, teses e outros materiais relevantes. O objetivo é priorizar estudos que apresentem metodologias avançadas e resultados comprovados, bem como revisões de literatura anteriores que ofereçam uma visão geral das tendências e lacunas nas áreas envolvidas.

Juntamente com seleção, é importante realizar uma leitura crítica dos materiais selecionados, avaliando a qualidade metodológica, a relevância dos resultados e a aplicabilidade das técnicas descritas. Além disso, é necessário identificar as abordagens mais promissoras e as limitações dos estudos existentes, com foco na integração entre aprendizagem profunda, visão computacional e astronomia.

2.1.3 Síntese e Documentação dos Estudos

Para que os estudos relevantes selecionados sejam facilmente encontrados em uma consulta posterior, é importante organizar as informações coletadas em categorias temáticas, como técnicas de extração de características visuais em imagens astronômicas, arquiteturas de redes neurais profundas específicas para análise de imagens, algoritmos de busca por similaridade visual, e aplicações práticas na astronomia. Elaborar uma síntese que destaque as principais contribuições, tendências emergentes e áreas de pesquisa futura.

A documentação dos estudos selecionados pela revisão bibliográfica servirá como referência fundamental para o desenvolvimento deste projeto, assegurando uma base teórica sólida e atualizada, além de ser um recurso essencial para a escrita da dissertação. Ela poderá ser feita incluindo comentários e discussões nos artigos selecionados, que podem incluir tecnologias utilizadas, principais resultados encontrados e lacunas de pesquisa identificadas. *Softwares* ou serviços de gerenciamento de bibliografia, como *Mendeley*, *Zotero* ou *Google Scholar* poderão ser utilizados para realização dessa tarefa.

2.2. CONJUNTO DE DADOS

2.2.1 Requisitos Funcionais e Não Funcionais

Primeiramente, é importante fazer um levantamento detalhado dos requisitos do sistema incluindo funcionalidade desejada, desempenho esperado e restrições técnicas, uma vez que armazenar, manipular e processar milhões de imagens provenientes de servidores externos consome recursos consideráveis de armazenamento, processamento e rede.

2.2.2 Protocolos e Padrões de Dados em Astronomia

Entidades como *National Aeronautics and Space Administration* (NASA, www.nasa.gov) e *International Virtual Observatory Alliance* (IVOA, www.ivoa.net) são responsáveis por propor diversos protocolos na área de astronomia que vão desde formatos de arquivos até protocolos de rede.

O *Flexible Image Transport System* (FITS, <http://fits.gsfc.nasa.gov>) é um formato binário de arquivo e uma das suas principais características é sua flexibilidade, que permite tanto o armazenamento de imagens quanto de tabelas, que são as principais estruturas de dados usadas na astronomia. Este formato de arquivo é compatível com o *World Coordinate System* (WCS), ou seja, é possível mapear cada píxel de uma imagem à uma posição real do céu, além de ser altamente eficiente em termos de armazenamento por possuir várias opções de compressão e quantização, tanto sem perdas quanto com perdas ajustáveis.

As consultas em bases de dados astronômicas são usualmente escritas usando a *Astronomical Data Query Language* (ADQL, www.ivoa.net/documents/ADQL), uma linguagem de consulta especificada pela IVOA e projetada especificamente para recuperar e manipular dados astronômicos armazenados em bancos de dados relacionais. Ela é um superconjunto da *Structured Query Language* (SQL), sendo adaptada para lidar com a complexidade e as necessidades específicas da astronomia, permitindo que pesquisadores realizem consultas sofisticadas sobre grandes conjuntos de dados astronômicos.

O acesso a servidores remotos para realizar consultas em bases de dados astronômicas é padronizado pelo *Table Access Protocol* (TAP, www.ivoa.net/documents/TAP),

um protocolo de rede que atua sobre a camada de aplicação² do modelo OSI (*Open Systems Interconnection*). Ele permite consultas escritas em SQL ou ADQL e especifica dois tipos de consultas: síncronas e assíncronas. No primeiro tipo, o cliente envia uma solicitação e aguarda a resposta do servidor. Esse tipo de consulta é adequado para operações rápidas e de pequena escala. No segundo tipo, o cliente envia uma solicitação e o servidor processa a consulta em segundo plano. O cliente pode verificar o estado da consulta periodicamente e recuperar os resultados quando estiverem processados. Isso é útil para consultas que demandam mais tempo.

2.2.3 Aquisição de Dados de Levantamentos Astronômicos

A aquisição de dados em levantamentos astronômicos depende do domínio dos protocolos listados na Seção 2.2.2. Além disso, cada levantamento astronômico possui seus próprios modelos de dados, sendo necessário analisar e entender sua estrutura para obtenção das informações desejadas.

A coleta de dados tem por objetivo a compilação de um conjunto de treinamento supervisionado, composto por imagens (*Legacy Survey*) e rótulos (*Galaxy Zoo*), para treinar o modelo de aprendizagem profunda (Seção 2.3.3) e, também, de um conjunto de busca, composto apenas por imagens, que será usado na inferência dos *embeddings* (Seção 2.3.5).


As imagens são acessadas de acordo com a posição do céu, definida por um sistema de coordenadas.

2.2.4 Sistema de Coordenadas Celeste

O sistema de coordenada equatorial é um dos principais sistemas de coordenadas celestes utilizados na astronomia para localizar objetos no céu. Baseado no prolongamento do plano equatorial da Terra no espaço, ele permite definir a posição de estrelas, planetas e outros corpos celestes de maneira precisa. A Fig. 2 mostra a representação desse sistema de coordenadas.

A Esfera Celeste é uma esfera imaginária de raio arbitrário, centrada na Terra, sobre a qual os astros parecem estar fixados. A esfera celeste facilita a representação

²A camada de aplicação é a sétima camada no modelo OSI e é responsável por fornecer serviços de rede diretamente aos aplicativos dos usuários.



■ **Figura 2:** Sistema de Coordenas Equatorial Geocêntrica. Fonte: Sky & Telescope

das coordenadas dos corpos celestes. O Plano do Equador Celeste é a projeção do plano equatorial da Terra na esfera celeste. Este plano divide a esfera celeste em dois hemisférios: norte e sul. Os Pólos Celestes são os pontos em que o eixo de rotação da Terra intercepta a esfera celeste. O Polo Norte Celeste está alinhado aproximadamente com a Estrela Polar.

A Ascensão Reta (*Right Ascension*) é a medida angular ao longo do equador celeste, partindo do ponto vernal (ou ponto Áries), que é a interseção do equador celeste com a eclíptica (o caminho aparente do Sol no céu ao longo do ano). A ascensão reta é medida em horas, minutos e segundos, variando de 0 a 24 horas. Cada hora corresponde a 15 graus de arco.

A Declinação (*Declination*) é a medida angular perpendicular ao equador celeste, indicando a distância de um objeto acima ou abaixo do equador. A declinação é expressa em graus, minutos e segundos de arco, variando de $+90^\circ$ no Polo Norte Celeste a -90° no Polo Sul Celeste.

2.2.5 Análise dos Dados

A compilação de um conjunto representativo de imagens astronômicas, abrangendo diferentes tipos de objetos celestes e fenômenos (por exemplo, galáxias espirais ou elípticas isoladas, sistema de galáxias em interação, galáxias irregulares, etc.) é altamente relevante para treinar um modelo com uma boa capacidade de generalização.

2.3. MODELO DE APRENDIZAGEM PROFUNDA

2.3.1 Seleção da Arquitetura

Uma etapa fundamental no desenvolvimento do modelo de aprendizagem profunda é a escolha de uma arquitetura de rede neural apropriada para a tarefa de geração de *embeddings* visuais, como Redes Neurais Convolucionais (CNN, [LeCun et al., 1998](#)) ou Vision Transformers (ViT, [Dosovitskiy et al., 2021](#)).

2.3.2 Pré-processamento dos Dados

O pré-processamento envolve a implementação de técnicas de pré-processamento para normalização, redimensionamento e aumento dos dados, visando melhorar a qualidade e a diversidade dos dados de treinamento para garantir uma melhor capacidade de generalização do modelo.

2.3.3 Treinamento

O treinamento supervisionado do modelo de aprendizagem profunda usando o conjunto de treinamento preparado (Seção 2.2) contendo as imagens e os rótulos provenientes dos volutários. Nesta etapa, ocorre os ajustes de hiperparâmetros para otimizar o desempenho do modelo, sendo essencial para garantir a capacidade de generalização da rede neural e para evitar o subajuste ou o sobreajuste.

2.3.4 Avaliação e Melhoria

A avaliação do modelo consiste em quantificar a capacidade preditiva do modelo utilizando métricas como precisão, recall e F1-score. Nessa etapa pode ocorrer a implementação de melhorias iterativas baseadas nos resultados obtidos.

2.3.5 Inferência

Após o treinamento (Seção 2.3.3) e avaliação (Seção 2.3.4) do modelo, é possível utilizá-lo no modo de inferência (ou predição) para geração dos *embeddings* que serão armazenados na base de dados (Seção 2.4).

2.4. BANCO DE DADOS E ALGORITMOS DE BUSCA

2.4.1 Design do Banco de Dados

A estruturação do banco de dados é essencial para o armazenamento eficiente dos vetores (*embeddings*). Atualmente, com o crescente uso de aprendizagem profunda nas aplicações, vários tipos de Sistema de Gerenciamento de Banco de Dados (SGBD) possuem suporte ao tipo de dado vetorial, essencial para o armazenamento dos *embeddings*, incluindo os SGBD's relacionais, orientados a documentos e orientados a vetores. Desse modo, é importante considerar os aspectos de escalabilidade e desempenho para fazer a escolha do melhor SGBD.

2.4.2 Indexação e Recuperação

Os algoritmos e estruturas de dados relacionados a indexação de vetores em um banco de dados possuem grande impacto no tempo de inserção e recuperação dos dados. Por isso, é necessária uma escolha minuciosa do algoritmo de indexação dos *embeddings* para permitir buscas rápidas e precisas por similaridade. Algumas estruturas de dados (e algoritmos) comumente usadas para esta finalidade são: Árvores k-dimensionais (KD-trees, GREENSPAN e YURICK, 2003), *Locality-Sensitive Hashing* (LSH, DATAR et al., 2004), *Hierarchical Navigable Small World* (HNSW, MALKOV e YASHUNIN, 2018) e *Inverted File Flat* (IVFFLAT, MALLIA et al., 2021).

2.4.3 Testes de Desempenho

Para assegurar que o banco de dados e os algoritmos de busca atendam aos requisitos de tempo de resposta e escalabilidade, é essencial a realização de testes de carga e desempenho.

2.5. APLICAÇÃO WEB

2.5.1 Design de Interface do Usuário

Criação de *wireframes* e protótipos da interface *web*, focando na usabilidade e acessibilidade para os usuários finais.

2.5.2 Implementação Front-end e Back-end

Desenvolvimento da aplicação web utilizando frameworks modernos, como React (www.react.dev) para *front-end* e Django (www.djangoproject.com) para *back-end*, além da integração do sistema de busca com a interface *web*.

2.5.3 Testes de Usabilidade

Realização de testes com usuários reais para coletar feedback sobre a interface e a experiência de uso e também da implementação de melhorias baseadas no feedback recebido.

2.6. SISTEMA INTELIGENTE PARA DESCOBERTAS EM ASTRONOMIA

2.6.1 Integração dos Módulos

O sistema é composto pelos seguintes módulos: um modelo de aprendizagem profunda aplicado à visão computacional (Seção 2.3), um banco de dados (Seção 2.4) e uma aplicação *web* (Seção 2.5). Cada módulo tem sua funcionalidade específica dentro do sistema e será implementado de forma independente. Isto é, os módulos poderão ser implementados paralelamente, aumentando o aproveitamento de tempo (conforme Fig. 3).

O *design* de *software* de cada módulo será feito de forma a garantir a integração contínua durante o desenvolvimento, permitindo a realização testes fim-a-fim e correção de possíveis incompatibilidades entre os módulos previamente.

2.6.2 Testes do Sistema

Os testes do sistema, ou testes fim-a-fim, tem como propósito garantir a qualidade e usabilidade do sistema como um todo, garantindo a interoperabilidade entre os seus módulos (descritos na Seção 2.6.1) no ambiente de produção.

2.7. COMPARAÇÃO DOS RESULTADOS

2.7.1 Identificação dos Critérios de Comparação

Selecionar os principais critérios de avaliação utilizados nos estudos de referência (Seção 2.1), como métricas de desempenho (ex: precisão, recall, F1-score), eficiência computacional (ex: tempo de processamento, uso de recursos), e aplicabilidade prática (ex: facilidade de uso, escalabilidade).

2.7.2 Coleta de Dados Comparativos

Após o desenvolvimento do sistema, coletar os dados de desempenho obtidos em experimentos controlados, utilizando os mesmos conjuntos de dados ou similares aos utilizados nos estudos selecionados. Garantir que os experimentos sejam reproduzíveis e documentados de forma detalhada.

2.7.3 Análise e Discussão

A análise quantitativa consiste em comparar os resultados numéricos do sistema desenvolvido com os dados dos estudos de referência utilizando gráficos, tabelas e estatísticas descritivas para visualizar as diferenças e similaridades. Alguns exemplos incluem: 1) a precisão na classificação de objetos astronômicos, 2) o tempo de resposta para busca por similaridade visual e 3) a robustez e generalização do modelo em diferentes conjuntos de dados astronômicos.

Por outro lado, a análise qualitativa consiste em realizar uma comparação dos resultados, discutindo as vantagens e limitações do sistema em relação aos métodos

existentes., considerando aspectos como inovação tecnológica, complexidade da implementação, e potencial de melhoria futura.

Finalmente, é importante elaborar uma discussão crítica e detalhada, identificando possíveis discrepâncias entre os resultados obtidos e os apresentados nas referências bibliográficas (Seção 2.1). Investigar as causas dessas discrepâncias, como diferenças nos conjuntos de dados, variações nos parâmetros dos modelos, ou melhorias implementadas no sistema proposto.

3. RESULTADOS ESPERADOS

Tendo em vista os objetivos enunciados na Seção 2, o resultado esperado é um sistema inteligente operante e funcional composto pelos seguintes módulos:

- Um modelo de aprendizagem profunda em visão computacional treinado e capaz de gerar *embeddings* a partir de imagens astronômicas.
- Um banco de dados para o armazenamento dos *embeddings* gerados pelo modelo de aprendizagem profunda baseado em algum sistema gerenciador de banco de dados existente, otimizado para busca em milhões de vetores (*embeddings*).
- Uma aplicação web intuitiva e dinâmica para realização das buscas.

Ao final do projeto, espera-se que o sistema desenvolvido não apenas atenda às necessidades imediatas de busca por similaridade visual em astronomia, mas também sirva como uma base para futuras inovações e melhorias em tecnologias de processamento e análise de imagens astronômicas. Assim, o sucesso deste projeto pode abrir novas possibilidades para a exploração do universo, além do avanço do conhecimento científico em outras áreas que enfrentam problemas similares de recuperação de informação semântica em imagens, como medicina, agricultura e geociências.

4. CONCLUSÃO

Nesta pesquisa, exploramos a eficácia de modelos de aprendizagem profunda para a tarefa de classificação de imagens em múltiplas campanhas do Galaxy Zoo. Inicialmente, discutimos a arquitetura do sistema inteligente e suas vantagens em


lidar com tarefas de visão computacional, destacando sua capacidade de capturar informações locais e globais por meio de atenção multi-eixo. Além disso, abordamos técnicas de treinamento e regularização utilizadas para melhorar o desempenho e a generalização do modelo.

Uma interface web para consulta de imagens por similaridade oferece uma plataforma intuitiva e acessível para os usuários explorarem grandes conjuntos de dados visuais de maneira eficiente e eficaz. Ao permitir que os usuários busquem por uma imagem de consulta, essa interface utiliza algoritmos de busca por similaridade visual, como o HNSW, combinados com embeddings de modelos como o MaxViT, para recuperar imagens semelhantes a partir de um banco de dados vasto. Isso proporciona uma experiência de busca visualmente rica, onde os usuários podem descobrir imagens relacionadas com rapidez e precisão, facilitando tarefas como encontrar inspiração criativa, identificar objetos específicos ou explorar conceitos visuais.

Uma das principais vantagens de uma interface web para consulta de imagens por similaridade é sua acessibilidade universal. Ao fornecer uma plataforma baseada na web, os usuários podem acessar a ferramenta a partir de qualquer dispositivo conectado à Internet, incluindo computadores desktop, laptops, tablets e smartphones. Isso torna a busca por imagens por similaridade uma tarefa conveniente e flexível, permitindo que os usuários explorem conteúdo visual de forma intuitiva em qualquer lugar e a qualquer momento.

Em suma, os resultados obtidos até o momento são encorajadores, demonstrando o potencial do sistema inteligente para a criação de representações de imagens em conjuntos de dados astronômicos. No entanto, são necessárias análises adicionais e ajustes para garantir a eficácia e a robustez do modelo em diferentes cenários de aplicação. Futuros trabalhos podem se concentrar em investigar ainda mais as causas da queda no desempenho e explorar estratégias adicionais para melhorar a capacidade de generalização do modelo.

5. CRONOGRAMA



■ Figura 3: Cronograma de atividades

REFERÊNCIAS

- BONNEY, RICK et al. (2016). “Can citizen science enhance public understanding of science?” Em: *Public Understanding of Science* 25.1. PMID: 26445860, pp. 2–16. DOI: [10.1177/0963662515607406](https://doi.org/10.1177/0963662515607406).
- DATAR, MAYUR et al. (2004). “Locality-sensitive hashing scheme based on p-stable distributions”. Em: *Proceedings of the Twentieth Annual Symposium on Computational Geometry*. SCG '04. Brooklyn, New York, USA: Association for Computing Machinery, pp. 253–262. ISBN: 1581138857. DOI: [10.1145/997817.997857](https://doi.org/10.1145/997817.997857).
- DEY, ARJUN et al. (mai. de 2019). “Overview of the DESI Legacy Imaging Surveys”. Em: *Astron. J.* 157.5, p. 168. ISSN: 0004-6256. DOI: [10.3847/1538-3881/ab089d](https://doi.org/10.3847/1538-3881/ab089d).
- DÍAZ, M. C. et al. (out. de 2017). “Observations of the first electromagnetic counterpart to a gravitational wave source by the TOROS collaboration”. Em: *arXiv*. DOI: [10.3847/2041-8213/aa9060](https://doi.org/10.3847/2041-8213/aa9060).
- DOSOVITSKIY, ALEXEY et al. (2021). “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. Em: *ICLR*.
- FANSON, JAMES L. et al. (ago. de 2022). *Overview and status of the Giant Magellan Telescope project*. Ed. por HEATHER K. MARSHALL, JASON SPYROMILIO e TOMONORI USUDA. DOI: [10.1117/12.2631694](https://doi.org/10.1117/12.2631694).
- FRIGERIO, DIDONE et al. (jan. de 2021). “Citizen Science in the Natural Sciences”. Em: *The Science of Citizen Science*. Cham, Switzerland: Springer, pp. 79–96. ISBN: 978-3-030-58278-4. DOI: [10.1007/978-3-030-58278-4_5](https://doi.org/10.1007/978-3-030-58278-4_5).
- GREENSPAN, MICHAEL e MIKE YURICK (2003). “Approximate kd tree search for efficient ICP”. Em: *Fourth International Conference on 3-D Digital Imaging and Modeling, 2003. 3DIM 2003. Proceedings*. IEEE, pp. 442–448. DOI: [10.1109/IM.2003.1240280](https://doi.org/10.1109/IM.2003.1240280).
- IVEZIĆ, ŽELJKO et al. (mar. de 2019). “LSST: From Science Drivers to Reference Design and Anticipated Data Products”. Em: *Astrophys. J.* 873.2, p. 111. ISSN: 0004-637X. DOI: [10.3847/1538-4357/ab042c](https://doi.org/10.3847/1538-4357/ab042c).
- KREMER, JAN et al. (mar. de 2017). “Big Universe, Big Data: Machine Learning and Image Analysis for Astronomy”. Em: *IEEE Intell. Syst.* 32.2, pp. 16–22. DOI: [10.1109/MIS.2017.40](https://doi.org/10.1109/MIS.2017.40).

- LECUN, YANN et al. (1998). “Gradient-based learning applied to document recognition”. Em: *Proceedings of the IEEE* 86.11, pp. 2278–2324. DOI: [10.1109/5.726791](https://doi.org/10.1109/5.726791).
- LINTOTT, CHRIS J., KEVIN SCHAWINSKI, ANŽE SLOSAR et al. (set. de 2008). “Galaxy Zoo: morphologies derived from visual inspection of galaxies from the Sloan Digital Sky Survey”. Em: *Monthly Notices of the RAS* 389.3, pp. 1179–1189. DOI: [10.1111/j.1365-2966.2008.13689.x](https://doi.org/10.1111/j.1365-2966.2008.13689.x). arXiv: [0804.4483](https://arxiv.org/abs/0804.4483) [astro-ph].
- MALKOV, YU A e DMITRY A YASHUNIN (2018). “Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs”. Em: *IEEE transactions on pattern analysis and machine intelligence* 42.4, pp. 824–836.
- MALLIA, ANTONIO et al. (jul. de 2021). “Learning Passage Impacts for Inverted Indexes”. English (US). Em: *SIGIR 2021 - Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. SIGIR 2021 - Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. Association for Computing Machinery, Inc, pp. 1723–1727. DOI: [10.1145/3404835.3463030](https://doi.org/10.1145/3404835.3463030).
- MARQUEZ, M. J. e BRIAN NORD (2019). “Challenges and Approaches for Mining Astronomical Data and Complex Models”. Em: *2019 IEEE International Conference on Big Data, Cloud Computing, Data Science & Engineering (BCD)*. IEEE, pp. 29–31. DOI: [10.1109/BCD.2019.8884988](https://doi.org/10.1109/BCD.2019.8884988).
- PADOVANI, PAOLO e MICHELE CIRASUOLO (jan. de 2023). “The Extremely Large Telescope”. Em: *Contemp. Phys.* DOI: [10.1080/00107514.2023.2266921](https://doi.org/10.1080/00107514.2023.2266921).
- THE EVENT HORIZON TELESCOPE COLLABORATION et al. (abr. de 2019). “First M87 Event Horizon Telescope Results. I. The Shadow of the Supermassive Black Hole”. Em: *Astrophys. J. Lett.* 875.1, p. L1. ISSN: 2041-8205. DOI: [10.3847/2041-8213/ab0ec7](https://doi.org/10.3847/2041-8213/ab0ec7).
- TULI, SHIKHAR et al. (mai. de 2021). “Are Convolutional Neural Networks or Transformers more like human vision?” Em: *arXiv*. DOI: [10.48550/arXiv.2105.07197](https://doi.org/10.48550/arXiv.2105.07197).



Universidade de São Paulo

Escola Politécnica

Departamento de Eng. da Computação e Sist. Digitais